



FACULTÉ DES SCIENCES APPLIQUÉES

MATH0488-1 ÉLÉMENTS DE PROCESSUS STOCHASTIQUES

Méthodes de Monte Carlo par chaînes de Markov pour la détection de communautés dans un graphe

Professeur :
Pierre GEURTS

Groupe :
Maxime FIRRINCIELI
Romain LAMBERMONT
Arthur LOUIS

10 mai 2022

Table des matières

1	Première partie : chaînes de Markov et algorithme MCMC	1
1.1	Chaînes de Markov	1
1.1.1	1
1.1.2	2
1.1.3	3
1.1.4	3
1.2	Méthode MCMC : analyse théorique dans le cas fini	4
1.2.1	4
1.2.2	4
1.3	Méthode MCMC : illustration sur un exemple simple	4
1.3.1	5
1.3.2	5
1.3.3	6
2	Deuxième partie : détection de communautés dans un graphe par algorithmes MCMC	6
2.1	Etude théorique	6
2.1.1	Théorème de bayes, cas général	6
2.1.2	7
2.1.3	7
2.1.4	7
2.2	Analyse expérimentale	8
2.2.1	8
2.2.2	9
2.3	Application à un grand graphe	9

Table des figures

1	Évolution des probabilités dans une distribution de départ uniforme	1
2	Évolution des probabilités dans une distribution de départ fixée sur 3	2
3	Proportion de l'état 1	3
4	Proportion de l'état 2	3
5	Proportion de l'état 3	3
6	Proportion de l'état 4	3
7	Convergence de la moyenne pour deux valeurs de r	5
8	Convergence de la variance pour deux valeurs de r	5
9	Evolution de la concordance en fonction du rapport b/a	8
10	Evolution de la concordance en fonction du rapport b/a	8

Liste des tableaux

1	Proportion des états obtenus en fonction de nombre de pas	3
---	---	---

Introduction

Ce projet a pour but de détecter les communautés dans un graphe grâce aux chaînes de Markov et par les méthodes de Monte-Carlo. L'utilisation de ces outils nous permettra de détecter efficacement les communautés dans un graphe. Le projet sera constitué en deux parties. Une première se focalisera sur la familiarisation avec les chaînes de Markov et les méthodes de Monte-Carlo, plus précisément l'algorithme de Metropolis-Hastings, tandis que la seconde sera le cœur du projet avec la recherche de communautés dans un graphe.

1 Première partie : chaînes de Markov et algorithme MCMC

1.1 Chaînes de Markov

Rappelons d'abord brièvement ce qu'est une chaîne de Markov. Une chaîne de Markov est un outil mathématique stochastique, qui utilise un principe de "non-mémoire". Tout état d'un système est simplement calculé à partir du précédent, ce qui en facilite l'analyse.

Ces chaînes sont simplement décrites mathématiquement comme suit avec X_1, X_2, \dots, X_t une suite de variables aléatoires qui définit une chaîne de Markov si (pour $t > 1$) elle suit cette relation :

$$\mathbb{P}(X_1, X_2, \dots, X_t) = \mathbb{P}(X_1) \prod_{l=2}^t \mathbb{P}(X_l | X_{l-1})$$

1.1.1

Nous calculons donc pour des valeurs de t croissantes les différentes valeurs demandées, ici avec $t = 20$ (suffit pour avoir convergé) :

- Cas de base distribué uniformément : $\mathbb{P}(X_t = x) = (0.3488 \quad 0.0698 \quad 0.2326 \quad 0.3488)$ avec $x = 1, 2, 3, 4$
- Cas de base fixé : $\mathbb{P}(X_t = x) = (0.3488 \quad 0.0698 \quad 0.2326 \quad 0.3488)$ avec $x = 1, 2, 3, 4$

$$Q^t = \begin{pmatrix} 0.3488 & 0.0698 & 0.2326 & 0.3488 \\ 0.3488 & 0.0698 & 0.2326 & 0.3488 \\ 0.3488 & 0.0698 & 0.2326 & 0.3488 \\ 0.3488 & 0.0698 & 0.2326 & 0.3488 \end{pmatrix}$$

On remarque donc bien une convergence vers des probabilités et ceci peut importe le cas de départ, on peut montrer cette convergence sur les figures ci-dessous :




FIGURE 1 – Évolution des probabilités dans une distribution de départ uniforme




FIGURE 2 – Évolution des probabilités dans une distribution de départ fixée sur 3

On remarque qu'après une vingtaine d'itérations on obtient la relation suivante :

$$Q^t = Q^{t-1}$$

On en déduit donc que $\lim_{t \rightarrow \infty} Q^t \approx Q^{20}$, en effet chaque ligne de Q^t est égale à $[0.3488, 0.0698, 0.2326, 0.3488]$. On a déjà remarqué dans les figures 1 et 2 que peu importe le point de départ, on converge vers les mêmes probabilités après un nombre suffisant d'itérations on montre alors avec $\pi_{t,\text{uniforme}}$ représentant la distribution des probabilités au pas de temps t dans le cas d'une distribution de base uniforme et $\pi_{t,\text{fixé}}$ représentant la distribution des probabilités au pas de temps t dans le cas d'une distribution de base fixée sur le cas 3 :

$$\begin{aligned}\pi_{21,\text{uniforme}} &= \pi_{20,\text{uniforme}}Q = \pi_{20,\text{uniforme}} \\ \pi_{21,\text{fixé}} &= \pi_{20,\text{fixé}}Q = \pi_{20,\text{fixé}}\end{aligned}$$

On dit d'une distribution qu'elle est stationnaire si $\pi_t = \pi_t Q$, nous considérons donc nos deux distributions comme stationnaires et elles admettent les propriétés suivantes :

- Ergodicité si elle est égale aux lignes de $\lim_{t \rightarrow \infty} Q^t$, comme prouvé dans la sous-section 1.1.4.
- Unicité si la chaîne de Markov est irréductible.

1.1.2

Afin de déduire la distribution stationnaire π_∞ de notre chaîne qui est décrite comme suit :

$$[\pi_\infty]_j = \lim_{t \rightarrow \infty} \mathbb{P}(X_t = j)$$

Nous allons simplement calculer $\mathbb{P}(X_t)$ avec un grand t ce qui nous donne :

$$\pi_\infty = (0.3488 \quad 0.0698 \quad 0.2326 \quad 0.3488)$$

1.1.3

Afin de vérifier les résultats obtenus, nous effectuons des réalisations de notre chaîne de Markov. Nous pouvons mettre en tableau la proportion de réalisation de chaque état lors de tests avec un nombre de pas croissant. Nous utilisons un point de départ distribué uniformément entre les 4 états car il a été prouvé plus haut que ça n'avait pas d'influence.

# Pas / État	1	2	3	4
100	0.35	0.05	0.21	0.39
1000	0.351	0.075	0.23	0.344
10000	0.346	0.064	0.236	0.354
100000	0.3501	0.0722	0.228	0.3497
1000000	0.34902	0.6757	0.23422	0.34919

TABLE 1 – Proportion des états obtenus en fonction de nombre de pas

En comparant ce tableau avec les résultats obtenus avec les valeurs précédemment obtenus, on remarque bien que les proportions sont respectées et font sens, on converge bien vers les mêmes valeurs.

Pour montrer plus de détails, on montre qu'on approche bien des valeurs des lignes de $\lim_{t \rightarrow \infty} Q^t$ avec des fluctuations qui s'atténuent plus t augmente :




FIGURE 3 – Proportion de l'état 1




FIGURE 4 – Proportion de l'état 2




FIGURE 5 – Proportion de l'état 3




FIGURE 6 – Proportion de l'état 4

1.1.4

Après ces premières expériences sur les chaînes de Markov et après avoir remarqué que les distributions sont comme attendu stationnaires, nous pouvons conclure que la chaîne de Markov que nous avons réalisé est ergodique. Une telle chaîne permet d'obtenir la distribution stationnaire de deux manières différentes, soit en effectuant des réalisations différentes, soit en effectuant une chaîne assez longue.

Pour être ergodique, une chaîne doit respecter 3 conditions :

1.2 Méthode MCMC : analyse théorique dans le cas fini

Nous allons maintenant nous attarder sur l'aspect théorique de l'algorithme de Metropolis-Hastings avant de passer à l'aspect pratique.

1.2.1

Soit π_0 une distribution initiale d'une chaîne de Markov invariante dans le temps et Q la matrice de transition :

$$\forall i, j \in \{1, \dots, N\} : \pi_0(i)[Q]_{i,j} = \pi_0(j)[Q]_{j,i}$$

Si π_0 est une distribution stationnaire de notre chaîne de Markov alors, avec Q la matrice de transition :

$$[\pi_0 Q]_j = [\pi_0]_j \quad (1)$$

Partons du membre de gauche :

$$\begin{aligned} [\pi_0 Q]_j &= \sum_{k=1}^N \pi_k Q_{k,j} && \text{(définition du produit scalaire)} \\ &= \sum_{k=1}^N \pi_j Q_{j,k} && \text{(par hypothèse des équations de balance détaillées)} \\ &= [\pi_0]_j \underbrace{\sum_{k=1}^N Q_{j,k}}_{=1} && \text{(définition de la matrice de transition)} \\ &= [\pi_0]_j && \text{(peut donc bien être une distribution stationnaire)} \end{aligned}$$

On peut finalement conclure sur l'unicité de π_0 . Pour que la distribution stationnaire soit unique, il faut que le chaîne de Markov soit irréductible, c'est-à-dire que si on représente notre chaîne selon un graphe avec un poids par arête représentant les probabilités, celui-ci doit être connexe.

1.2.2

En repartant du résultat précédemment obtenu :

$$\forall i, j \in 1, \dots, N : \pi_0(i)[Q]_{i,j} = \pi_0(j)[Q]_{j,i}$$

1.3 Méthode MCMC : illustration sur un exemple simple

Nous allons maintenant nous attarder à un cas plus précis de l'algorithme de Metropolis-Hastings pour échantillonner des valeurs suivant la distribution binomiale définie comme suit avec p la probabilité de succès :

$$\mathbb{P}(X = k) = C_K^k p^k (1-p)^{K-k}$$

Pour ce faire nous allons utiliser la distribution de proposition énoncée avec $r \in]0, 1[$ comme suit :

$$q(y|x) = \begin{cases} r & \text{si } x = 0 \text{ et } y = 0 \\ (1-r) & \text{si } x = K \text{ et } y = K \\ r & \text{si } 0 < x \leq K \text{ et } y = x-1 \\ (1-r) & \text{si } 0 \leq x < K \text{ et } y = x+1 \\ 0 & \text{sinon} \end{cases}$$

1.3.1

Au vu du choix de notre distribution $q(y|x)$ qui est symétrique, on sait que lors du calcul de

$$\frac{p_X(y^{(t)})}{p_X(x^{(t-1)})} \frac{q(x^{(t-1)}|y^{(t)})}{q(y^{(t)}|x^{(t-1)})}$$

La deuxième partie de ce produit se simplifiera au vu de la symétrie de la distribution car

$$q(x^{(t-1)}|y^{(t)}) = q(y^{(t)}|x^{(t-1)})$$

On conclut donc que $q(y|x)$ est un bon choix de distribution pour notre algorithme de Metropolis-Hastings comme vu au point 1.2.2 .

1.3.2

Nous allons maintenant réaliser une grande réalisation de notre chaîne de Markov afin de constater la présence d'une convergence :




FIGURE 7 – Convergence de la moyenne pour deux valeurs de r




FIGURE 8 – Convergence de la variance pour deux valeurs de r

Au vu des deux figures ci-dessus, on remarque bien que les valeurs convergent et à des taux différents en fonction de r . En effet, plus r est grand, plus on converge rapidement et ce car plus r grandit, plus

la proportion du cas $0 \leq x \leq K$ et $y = x - 1$ va prendre de l'importance dans notre distribution. Ce qui provoquera une convergence

1.3.3

2 Deuxième partie : détection de communautés dans un graphe par algorithmes MCMC

2.1 Etude théorique

2.1.1 Théorème de Bayes, cas général

Pour commencer, rappelons nous le théorème de Bayes dans sa forme général :

$$\mathbb{P}(x|y) = \frac{\mathbb{P}(y|x) * \mathbb{P}(x)}{\mathbb{P}(y)}$$

Dans le cadre de ce projet, nous obtenons :

$$\mathbb{P}(x|G) = \frac{\mathbb{P}(G|x) * \mathbb{P}(x)}{\mathbb{P}(G)}$$

Regardons maintenant de plus près les 3 termes de notre équation :

$$\begin{aligned} \mathbb{P}(x) &= \prod_{u=1}^n p_{x_u} \\ &= \prod_{i=1}^n p_i^{|\Omega_i(x)|} \end{aligned}$$

$$\begin{aligned} \mathbb{P}(G|x) &= \prod_{1 \leq u < v \leq n} W_{x_u, x_v}^{G_{u,v}} (1 - W_{x_u, x_v})^{1 - G_{u,v}} \\ &= \prod_{1 \leq i \leq j \leq k} W_{i,j}^{N_{i,j}(x,G)} (1 - W_{i,j})^{N_{i,j}^c(x,G)} \end{aligned}$$

$$\mathbb{P}(G) = \int \mathbb{P}(G|x) dx$$

Nous avons donc au final :

$$\mathbb{P}(x|G) = \frac{\prod_{i=1}^n p_i^{|\Omega_i(x)|} \prod_{1 \leq i \leq j \leq k} W_{i,j}^{N_{i,j}(x,G)} (1 - W_{i,j})^{N_{i,j}^c(x,G)}}{\int \mathbb{P}(G|x) dx}$$

où :

$$\begin{aligned} N_{i,j}(x, G) &= \sum_{u < v, x_u = i, x_v = j} \mathbb{1}(G_{uv} = 1) \\ N_{i,j}^c(x, G) &= \sum_{u < v, x_u = i, x_v = j} \mathbb{1}(G_{uv} = 0) \\ &= |\Omega_i(x)| * |\Omega_j(x)| - N_{i,j}(x, G) \text{ si } i \neq j \\ &= \frac{|\Omega_i(x)| * (|\Omega_i(x)| - 1)}{2} - N_{i,i}(x, G) \text{ si } i = j \end{aligned}$$

Dans le cas d'une distribution $SBM(N, K, p, A, B)$, la probabilité $\mathbb{P}(x|G)$ sera simplifiée.

$$\begin{aligned} \mathbb{P}(G|x) &= \prod_{1 \leq i \leq j \leq k} A^{N_{i,i}(x,G)} (1 - A)^{N_{i,i}^c(x,G)} \text{ si } i = j \\ &= \prod_{1 \leq i \leq j \leq k} B^{N_{i,j}(x,G)} (1 - B)^{N_{i,j}^c(x,G)} \text{ si } i \neq j \end{aligned}$$

2.1.2

Le terme qui va devenir un problème si N augmente, est le dénominateur de la fraction finale du point précédent. En effet, la complexité du calcul de l'intégral est exponentielle par rapport à N . Cependant, il n'est pas nécessaire de connaître ce terme car nous souhaitons maximiser $\mathbb{P}(x|G)$ et l'intégrale agira comme une constante. Elle n'apporte donc rien au problèmes de maximisation.

2.1.3

2.1.4

Le taux d'acceptation α peut être exprimé :

$$\begin{aligned} \alpha &= \frac{\mathbb{P}(x_t|G)}{\mathbb{P}(x_{t-1}|G)} \\ &= \frac{\prod_{i=1}^n p_i^{|\Omega_i(x_t)|} \prod_{1 \leq i \leq j \leq k} W_{i,j}^{N_{i,j}(x_t, G)} (1 - W_{i,j})^{N_{i,j}^c(x_t, G)}}{\int \mathbb{P}(G|x) dx} \\ &= \frac{\prod_{i=1}^n p_i^{|\Omega_i(x_t)|} \prod_{1 \leq i \leq j \leq k} W_{i,j}^{N_{i,j}(x_t, G)} (1 - W_{i,j})^{N_{i,j}^c(x_t, G)}}{\prod_{i=1}^n p_i^{|\Omega_i(x_{t-1})|} \prod_{1 \leq i \leq j \leq k} W_{i,j}^{N_{i,j}(x_{t-1}, G)} (1 - W_{i,j})^{N_{i,j}^c(x_{t-1}, G)}} \\ &= \frac{\prod_{i=1}^n p_i^{|\Omega_i(x_t)|} \prod_{1 \leq i \leq j \leq k} W_{i,j}^{N_{i,j}(x_t, G)} (1 - W_{i,j})^{N_{i,j}^c(x_t, G)}}{\prod_{i=1}^n p_i^{|\Omega_i(x_{t-1})|} \prod_{1 \leq i \leq j \leq k} W_{i,j}^{N_{i,j}(x_{t-1}, G)} (1 - W_{i,j})^{N_{i,j}^c(x_{t-1}, G)}} \end{aligned}$$

Comme le taux α sera calculé numériquement, il est intéressant de calculer son logarithme.

$$\begin{aligned} \log(\mathbb{P}(x|G)) &= \sum_{i=1}^k |\Omega_i(x)| \log(p_i) + \sum_{1 \leq i \leq j \leq k} N_{i,j}(x, G) \log(W_{i,j}) + N_{i,j}^c(x, G) \log(1 - W_{i,j}) \\ \log \alpha &= \log(\mathbb{P}(x_t|G)) - \log(\mathbb{P}(x_{t-1}|G)) \\ &= \sum_{i=1}^k |\Omega_i(x_t)| \log(p_i) + \sum_{1 \leq i \leq j \leq k} N_{i,j}(x_t, G) \log(W_{i,j}) + N_{i,j}^c(x_t, G) \log(1 - W_{i,j}) \\ &\quad - \sum_{i=1}^k |\Omega_i(x_{t-1})| \log(p_i) - \sum_{1 \leq i \leq j \leq k} N_{i,j}(x_{t-1}, G) \log(W_{i,j}) + N_{i,j}^c(x_{t-1}, G) \log(1 - W_{i,j}) \\ &= \sum_{i=1}^k (|\Omega_i(x_t)| - |\Omega_i(x_{t-1})|) \log(p_i) + \sum_{1 \leq i \leq j \leq k} (N_{i,j}(x_t, G) - N_{i,j}(x_{t-1}, G)) \log(W_{i,j}) \\ &\quad + \sum_{1 \leq i \leq j \leq k} (N_{i,j}^c(x_t, G) - N_{i,j}^c(x_{t-1}, G)) \log(1 - W_{i,j}) \end{aligned}$$

2.2 Analyse expérimentale

2.2.1

Les graphiques qui vont suivre ont été générés avec une distribution $SBM(500, 2, [0.5, 0.5], a/500, b/500)$




FIGURE 9 – Evolution de la concordance en fonction du rapport b/a




FIGURE 10 – Evolution de la concordance en fonction du rapport b/a

En comparant les 2 graphiques, on remarque rapidement que moins les communautés ont de liens entre elles, plus l'algorithme de Metropolis-Hastings les détecte avec précisions. A partir d'un rapport $b/a = 0.2$ notre algorithme ne donne aucun résultats concluants

2.2.2

En considérant un degré moyen de 3 pour $\frac{a+b}{2}$, nous arrivons à ces conclusions :

$$(a - b)^2 > 2 * (a + b)$$

$$(a - b)^2 > 2 * 12$$

$$(a - b) > \sqrt{24} = 2 * \sqrt{6}$$

$$a > b + 2 * \sqrt{6}$$

$$a > 6 - a + 2 * \sqrt{6}$$

$$2 * a > 6 + 2 * \sqrt{6}$$

$$a > 3 + \sqrt{6} \simeq 5,45$$

La condition n'est donc plus respectées pour le rapport $b/a = \frac{6-5,45}{5,45} = 0,092$

2.3 Application à un grand graphe